

گروه ۲

پیش از کشف الگوهای اضطراب داستان آماده‌سازی داده‌ها

اضطراب اجتماعی موضوع اصلی این پروژه است اما برای بررسی آن، تنها نگاه کردن به نمره اضطراب کافی نیست. در کنار این نمره، مجموعه‌ای از اطلاعات درباره خواب، فعالیت بدنی، مصرف کافئین، استرس، نشانه‌های جسمی و سابقه درمان قرار دارد. سوال اول ما این بود: در این مجموعه داده، کدام ویژگی‌ها با نمره اضطراب همراه‌اند و چه تفاوت‌هایی میان گروه‌های مختلف دیده می‌شود؟

پاسخ دادن به این سوال، پیش از هر نمودار مقایسه‌ای یا آزمون آماری، به یک کار ضروری نیاز داشت: شناخت کیفیت داده‌ها. اگر ساعت خواب فردی منفی ثبت شده باشد یا اطلاعات ثبت نشده را به اشتباه به معنی نداشتن سابقه در نظر بگیریم، تحلیل می‌تواند داستانی تعریف کند که بیشتر حاصل خطاهای داده است تا الگوهای واقعی آن. بنابراین نخستین بخش سفر ما به بررسی و آماده‌سازی داده‌ها اختصاص یافت.

در شروع، با جدولی شامل ۲۰۳۰ رکورد و ۲۲ ستون روبه‌رو شدیم. هر ردیف شامل اطلاعات ثبت شده برای یک فرد بود از ویژگی‌های جمعیت‌شناختی مانند سن، جنسیت و شغل تا عادت‌های روزمره، شاخص‌های جسمی و نمره اضطراب. این تنوع، فرصت بررسی ارتباط‌های مختلف را فراهم می‌کرد ولی اول لازم بود مشخص شود چه اطلاعاتی موجود است، چه بخش‌هایی ناقص‌اند و کدام مقادیر نیاز به بررسی دارند.

با مرور اولیه فهمیدیم که داده‌ها به یک اندازه کامل نیستند. در بعضی ستون‌ها، مانند سن و خواب، بخشی از اطلاعات ثبت نشده بود. در مقابل، ستون سابقه درمان وضعیت متفاوتی داشت: ۹۰ درصد مقادیر آن، معادل ۱۸۲۷ رکورد، خالی بود. این نخستین محدودیت مهم تحلیل بود. درباره بیشتر افراد، نمی‌دانستیم سابقه درمان آن‌ها چه بوده است و این ندانستن را نمی‌شد با نداشتن سابقه درمان یکی بدوینیم.

بررسی ردیف‌های کاملاً تکراری، موردی پیدا نکرد. با این حال، در میان ستون‌ها یک تکرار وجود داشت: دو ستون **Target** و **is_Anxious** در تمام ۲۰۳۰ ردیف، مقادیر یکسانی داشتند. برای جلوگیری از نگهداری اطلاعات تکراری، ستون **is_Anxious** حذف و **Target** حفظ شد. به این ترتیب، تعداد ستون‌ها به ۲۱ رسید، بدون آنکه رکوردی حذف شود.

در بررسی بعدی، رابطه برچسب هدف با نمره اضطراب نیز روشن شد. در تمام رکوردها، نمره اضطراب ۷ و بالاتر با برچسب یک و نمره کمتر از ۷ با برچسب صفر همراه بود. پس در ادامه گزارش، منظور از گروه دارای برچسب یک، افراد دارای نمره اضطراب ۷ و بالاتر در همین دیتاست است. این تعریف، مبنای مقایسه گروه‌ها خواهد بود و به تنهایی معادل تشخیص نیست.

با رد شدن از شناخت ساختار جدول، نوبت به بررسی درست بودن مقادیر رسید. در ستون‌های خواب، فعالیت بدنی و مصرف الکل، مقادیر منفی وجود داشت مقدیری که با مفهوم این متغیرها سازگار نیستند. همچنین در ستون استرس، با وجود تعریف مقیاس ۱ تا ۱۰، مقدار ۱۵ دیدیم. این موارد به **Missing Value** تبدیل شدند تا در مرحله بعد مدیریت شوند. در این فرایند، فقط خانه‌های نامعتبر تغییر کردند و سایر اطلاعات همان افراد حفظ شد.

همه موارد غیرعادی، به صورت واضح نامعتبر نبودند. مثلاً، مصرف کافئین ۱۵۰۰ میلی گرم در روز و ضربان قلب ۲۲۰، هرکدام در ۳۰ رکورد ثبت شده بود. تکرار این مقادیر و فاصله آن‌ها از بقیه مشاهدات، باعث شد در فرایند پاک‌سازی به‌عنوان مقادیر مشکوک در نظر گرفته شوند و با مقدار گمشده جایگزین شوند.

این تصمیم با اصلاح خواب منفی تفاوت داشت: نامعتبر بودن خواب منفی روشن است، اما مشکوک بودن یک مقدار بالا، خطای ثبت‌بودن آن را اثبات نمی‌کند. از این‌رو، این تغییرات بخشی از فرض‌های پاک‌سازی پروژه هستند و باید هنگام تفسیر نتایج در نظر گرفته شوند. بررسی حساسیت یافته‌های نهایی به حفظ یا جایگزینی این مقادیر، می‌تواند میزان اتکاپذیری نتایج را روشن‌تر کند.

برای شناخت بهتر پراکندگی داده‌ها، نمودارهای توزیع و نمودارهای جعبه‌ای بررسی شدند. این نمودارها نشان دادند که بعضی مشاهدات از محدوده معمول ستون خود فاصله دارند اما داده پرت لزوماً داده اشتباه نیست. در ستون تعداد جلسات درمان، مقادیر بالاتر از شش جلسه در ماه بر اساس روش فاصله بین چارکی، پرت آماری شناخته شدند. با این حال، چون این مقادیر از نظر تعریف متغیر ناممکن نبودند، تغییرش ندادیم.

برای خواب و فعالیت بدنی، تصمیم متفاوتی گرفته شد. مقادیر فعالیت بدنی بالاتر از ۸/۲۵ ساعت در هفته به همین حد محدود شدند. ساعت خواب نیز به بازه حدود ۳/۵ تا ۹/۹ ساعت محدود شد. در این روش، فرد از جدول حذف نمی‌شود مقدار خارج از محدوده به نزدیک‌ترین کران منتقل می‌شود.

این اقدام تعداد رکوردها را حفظ کرد، اما بخشی از تفاوت‌های واقعی احتمالی در انتهای توزیع را نیز کاهش داد. بنابراین کمترین و بیشترین مقادیر خواب و فعالیت بدنی در نسخه آماده‌شده، صرفاً توصیف مشاهدات اولیه نیستند بلکه تا حدی نتیجه تصمیم‌های پاک‌سازی‌اند. این موضوع در تحلیل‌های بعدی، به‌ویژه هنگام بررسی کم‌خوابی یا فعالیت بدنی زیاد، اهمیت خواهد داشت.

پس از مدیریت مقادیر نامعتبر و مشکوک، تصویر کامل‌تری از اطلاعات گمشده به دست آمد. به‌جز سابقه درمان که همچنان ۹۰ درصد آن ناموجود بود، سهم مقادیر خالی در ستون کافئین حدود ۶/۱۱ درصد، جنسیت ۵/۸۶ درصد، دارو ۵/۳۷ درصد و سیگار ۵/۲۲ درصد بود. بخشی از این کمبودها از ابتدا وجود داشت و بخشی دیگر نتیجه کنارگذاشتن مقادیر مسئله‌دار بود.

برای حفظ رکوردها، خانه‌های خالی ستون‌های دسته‌ای با پرتکرارترین مقدار همان ستون پر شدند. در ستون‌های عددی نیز از میانه استفاده شد یعنی مقداری که پس از مرتب‌کردن داده‌ها در مرکز قرار می‌گیرد. برای نمونه، مقادیر گمشده خواب با ۶/۷ ساعت، سن با ۴۰ سال و کافئین با ۲۷۵ میلی گرم در روز جایگزین شدند.

این جایگزینی‌ها امکان ادامه تحلیل را فراهم می‌کنند، اما اطلاعات تازه‌ای درباره افراد به دست نمی‌دهند. به عبارت دیگر، مقدار جایگزین‌شده یک تخمین است، نه مشاهده واقعی. همچنین تکرار یک مقدار مرکزی می‌تواند پراکندگی داده را کاهش دهد یا در نمودار توزیع، تجمعی ایجاد کند. به همین دلیل، پس از جایگزینی، نمودارها دوباره بررسی شدند تا تاثیر تصمیم‌های پاک‌سازی نیز دیده شود.

مقایسه نمودارهای قبل و بعد نشان داد که آماده‌سازی داده‌ها فرایندی خنثی نیست. برای مثال، پس از جایگزینی مقادیر گمشده کافئین با میانه، تجمع بیشتری اطراف مقدار میانی دیده شد. چنین الگویی نباید تماماً به رفتار افراد نسبت داده شود چون بخشی از آن حاصل روش آماده‌سازی داده است.

در ادامه، شکل توزیع متغیرهای عددی بررسی شد. بیشتر ستون‌ها چولگی شدیدی نداشتند، اما تعداد جلسات درمان راست‌چوله‌تر بود یعنی بخش بزرگی از افراد جلسات کمتری داشتند و تعداد کمتری در مقادیر بالاتر قرار می‌گرفتند. آزمون شاپیرو-ویلک نیز در سطح معناداری ۰/۰۵، فرض نرمال بودن را برای تمام ستون‌های عددی بررسی شده رد کرد. این نتیجه به معنی نامعتبر بودن داده‌ها نیست بلکه نشان می‌دهد انتخاب روش‌های تحلیلی بعدی باید با توجه به شکل توزیع، نوع متغیر و فرض‌های هر روش انجام شود.

ستون سابقه درمان به صورت جداگانه مدیریت شد. دسته‌های ثبت‌شده، شامل گروه‌درمانی، روان‌درمانی پویشی، درمان شناختی-رفتاری و نداشتن سابقه قبلی، به کدهای عددی تبدیل شدند. برای اطلاعات ثبت‌نشده نیز کد مستقلی در نظر گرفته شد تا با بدون سابقه درمان اشتباه نشود. این اعداد صرفاً شناسه دسته‌ها هستند و نشان‌دهنده شدت، کیفیت یا ترتیب درمان نیستند. همچنین کدگذاری، محدودیت ناشی از نبود اطلاعات برای ۹۰ درصد رکوردها را برطرف نمی‌کند.

در پایان این مرحله، نسخه آماده‌شده با ۲۰۳۰ رکورد و ۲۱ ستون ذخیره شد. هیچ ردیفی حذف نشد ستون هدف تکراری کنار گذاشته شد، مقادیر نامعتبر و مشکوک مدیریت شدند، بخشی از مقادیر انتهایی محدود شدند و اطلاعات گم‌شده با روش‌های تعیین‌شده جایگزین یا به صورت یک دسته مستقل مشخص شدند.

تا این لحظه، هنوز نمی‌توان گفت کدام عامل بیشترین ارتباط را با اضطراب دارد یا تفاوت گروه‌ها چقدر است. دستاورد این مرحله، شناخت بهتر داده‌ها و تصمیم‌هایی است که مبنای تحلیل بعدی خواهند بود. اکنون می‌دانیم کدام بخش‌ها مستقیماً مشاهده شده‌اند، کدام مقادیر تخمین زده شده‌اند و در کجا اطلاعات کافی نداریم. ادامه داستان، از همین جا آغاز می‌شود: بررسی رابطه‌ها و تفاوت‌ها، با حفظ مرز میان آنچه داده‌ها نشان می‌دهند و آنچه هنوز نمی‌توان از آن‌ها نتیجه گرفت.

از داده‌های آماده‌شده تا نخستین الگوهای اضطراب

پس از آماده‌سازی داده‌ها، پرسش اصلی دوباره پیش روی ما قرار گرفت: چه تفاوت‌هایی میان افراد مضطرب و غیرمضطرب دیده می‌شود؟ این بار، به‌جای بررسی خطاها و خانه‌های خالی، به دنبال الگوهایی بودیم که بتوانند تصویر روشن‌تری از زندگی روزمره افراد ارائه دهند.


در مجموعه ۲۰۳۰ رکورد، ۲۱۰ نفر، معادل حدود ۱۰/۳ درصد نمونه، مضطرب بودند. ۱۸۲۰ نفر دیگر غیرمضطرب بودند. این تقسیم‌بندی، تعریف برجسب هدف در دیتاست بود و نباید به‌تنهایی معادل تشخیص واقعی تلقی شود.

نخستین مقایسه‌ها نشان دادند که تفاوت دو گروه در همه ویژگی‌ها به یک اندازه آشکار نیست. بعضی نمودارها هم‌پوشانی زیادی داشتند، اما در خواب، فعالیت بدنی، استرس، تغذیه و تعداد جلسات درمان، الگوهای روشن‌تری دیده می‌شد. این مشاهدات، مسیر بررسی دقیق‌تر را مشخص کردند.

یکی از واضح‌ترین تفاوت‌ها در ساعت خواب ظاهر شد. میانگین خواب در افراد غیرمضطرب، حدود ۶/۸۷ ساعت بود درحالی‌که این مقدار برای افراد مضطرب به حدود ۴/۹۳ ساعت می‌رسید. فاصله دو میانگین نزدیک به دو ساعت بود. میانه خواب نیز همین تصویر را نشان داد: ۶/۸ ساعت در گروه اول، در برابر ۴/۸ ساعت در گروه دوم.

بنابراین تفاوت مشاهده‌شده فقط به چند مقدار بسیار کم یا زیاد محدود نبود. مرکز توزیع خواب دو گروه نیز فاصله قابل‌توجهی داشت. آزمون آماری یک‌طرفه من-ویتنی، شواهد بسیار قوی از تفاوت توزیع خواب نشان داد. بازه‌های اطمینان برآورد میانگین نیز از یکدیگر جدا بودند: حدود ۶/۸۳ تا ۶/۹۲ ساعت در افراد غیرمضطرب و ۴/۸۰ تا ۵/۰۶ ساعت در افراد مضطرب.

برای اینکه این تفاوت فقط به اعداد خلاصه نشود، توزیع ساعت خواب دو گروه نیز به صورت هم‌زمان بررسی شد. همان‌طور که در شکل ۱ دیده می‌شود، بخش عمده افراد غیرمضطرب در ساعت‌های خواب بیشتر قرار دارند، در حالی که توزیع افراد مضطرب به سمت خواب کمتر جابه‌جا شده است. این فاصله، همان الگویی را که در میانگین و میانه دیده شد، در شکل توزیع داده‌ها نیز نشان می‌دهد.




شکل ۱. مقایسه توزیع ساعت خواب در افراد مضطرب و غیرمضطرب

این یافته، خواب را به یکی از اصلی‌ترین کاندیدهای داستان داده‌ها تبدیل کرد. با این حال، از این مقایسه نمی‌توان مشخص کرد که خواب کمتر پیش از اضطراب وجود داشته، پس از آن ایجاد شده یا هر دو با عوامل دیگری مرتبط بوده‌اند. آنچه داده‌ها نشان می‌دهند، همراهی روشن خواب کمتر با مضطرب‌بودن در همین نمونه است.

تغذیه، سرخ مهم بعدی بود. برای ساده‌تر شدن مقایسه، افراد بر اساس نمره کیفیت تغذیه به دو گروه تقسیم شدند: نمره کمتر از ۵ و نمره ۵ و بالاتر. در گروه نخست، ۱۸۳ نفر از ۸۷۸ نفر، یعنی حدود ۲۰/۸ درصد، مضطرب بودند. در گروه دوم، این تعداد ۲۷ نفر از ۱۱۵۲ نفر، معادل حدود ۲/۳ درصد بود.

به زبان ساده، در گروه نمره تغذیه پایین‌تر، تقریباً یک نفر از هر پنج نفر مضطرب بود در گروه نمره تغذیه بالاتر، این سهم نزدیک به یک نفر از هر ۴۳ نفر بود. نسبت این دو سهم حدود ۸/۹ برابر و فاصله آن‌ها حدود ۱۸/۵ واحد درصد بود. آزمون استقلال نیز شواهد قوی از ارتباط این گروه‌بندی با برجسب اضطراب نشان داد.

برای اینکه این تفاوت به صورت دیداری هم مشخص شود، سهم افراد مضطرب و غیرمضطرب در دو گروه کیفیت تغذیه به صورت نمودار مقایسه شد. همان‌طور که در شکل ۲ دیده می‌شود، سهم افراد مضطرب در گروه دارای رژیم ضعیف به شکل محسوسی بیشتر از گروه دارای رژیم خوب است و این تصویر همان اختلافی را که در درصدها دیده شد، تایید می‌کند.




شکل ۲. مقایسه سهم افراد مضطرب و غیرمضطرب در دو گروه کیفیت رژیم غذایی

با وجود این اختلاف بزرگ، مرز نمره ۵ یک انتخاب تحلیلی است. همچنین بخشی از نمره‌های تغذیه در مرحله آماده‌سازی با میانه جایگزین شده‌اند. بنابراین این مقایسه باید به‌عنوان یک ارتباط مشاهده‌شده تفسیر شود نه اثبات اینکه تغییر تغذیه، به‌تنهایی همین میزان تغییر در اضطراب ایجاد خواهد کرد.

در بررسی شغل‌ها، داستان پیچیده‌تر شد. سهم افراد مضطرب در گروه معلمان حدود ۱۳/۲ درصد و در فریلنسرها حدود ۵/۲ درصد بود. در نگاه اول، فاصله این دو گروه جلب توجه می‌کرد و آزمون جداگانه آن‌ها نیز از مرز معناداری عبور می‌کرد.

برای اینکه این تفاوت بهتر دیده شود، سهم افراد مضطرب و غیرمضطرب در این دو شغل به صورت نمودار مقایسه شد. همان‌طور که در شکل ۳ مشاهده می‌شود، در گروه معلمان سهم افراد مضطرب بیشتر از گروه فریلنسرهاست. این نمودار فقط مقایسه همین دو گروه را نشان می‌دهد و هنوز به معنی تفاوت قطعی میان همه مشاغل نیست.



شکل ۳. مقایسه سهم افراد مضطرب و غیرمضطرب در گروه معلمان و فریلنسرها

اما این دو گروه پس از مشاهده همه شغل‌ها و به دلیل داشتن بیشترین فاصله انتخاب شده بودند. برای بررسی تصویر کامل‌تر، در بازبینی تکمیلی، تمام ۱۳ گروه شغلی هم‌زمان مقایسه شدند. این آزمون کلی، شواهد کافی برای رد استقلال شغل و برچسب اضطراب نشان نداد.

این بخش یادآور شد که بزرگ‌ترین فاصله یک جدول، الزاما قابل‌اتکاترین یافته آن نیست. تفاوت معلمان و فریلنسرها می‌تواند موضوع بررسی بعدی باشد، اما در این مرحله مبنای محکمی برای تعمیم درباره نقش شغل فراهم نمی‌کند.


پس از مقایسه ویژگی‌ها به صورت جداگانه، پرسش تازه‌ای مطرح شد: آیا کنار هم قرار دادن چند ویژگی، تصویر روشن‌تری به دست می‌دهد؟ برای پاسخ، نسبت کافئین به خواب، نسبت استرس به خواب و یک امتیاز ترکیبی از تغذیه، فعالیت بدنی، خواب، استرس و چند رفتار روزمره ساخته شد.

این ویژگی‌ها برای خلاصه کردن اطلاعات به کار رفتند. برای مثال، نسبت استرس به خواب، وضعیتی را برجسته می‌کند که فرد هم‌زمان استرس بیشتری و خواب کمتری دارد. در نمودارها، افراد مضطرب بیشتر در مقادیر بالای این نسبت و مقادیر پایین‌تر امتیاز ترکیبی سبک زندگی قرار می‌گرفتند.

بالین حال، این امتیازها ابزارهای اکتشافی ساخته شده برای پروژه هستند. نام‌گذاری آن‌ها به معنی اعتبار علمی واقعی یا توانایی تشخیص سلامت، فرسودگی یا بیماری نیست. همچنین نتیجه آن‌ها به انتخاب مولفه‌ها و وزن‌ها وابسته است.

برای بررسی هم‌زمان چند متغیر (چندستونی)، از مدل‌های رگرسیون لجستیک استفاده کردیم. از میان ترکیب‌های بررسی شده، خواب همراه با تعداد جلسات درمان، و ترکیب خواب، استرس و فعالیت بدنی، بالاترین امتیازهای فیت شدن را داشتند. امتیاز ترکیبی سبک زندگی نیز در میان رتبه‌های بالای فهرست قرار گرفت.

Logistic Regression



شکل ۴: اسلاید جلسه ۱۹ درس هوش مصنوعی - استاد آرش ماری‌اوریاد - دانشگاه صنعتی شریف - پاییز ۱۴۰۴

در مدل شامل خواب، استرس و فعالیت بدنی، جهت ارتباطها با مشاهدات اولیه سازگار بود: خواب و فعالیت بدنی بیشتر با شانس کمتر مضطرب‌بودن همراه بودند و استرس بیشتر با شانس بالاتر همراه بود. این روابط، با در نظر گرفتن هم‌زمان سه متغیر در همان مدل مشاهده شدند اما به معنی کنترل تمام عوامل احتمالی یا اثبات رابطه علت‌ومعلولی نیستند.

تعداد جلسات درمان نیز در چند مدل برجسته ظاهر شد. در این نمونه، افراد مضطرب به‌طور متوسط حدود ۶/۱۸ جلسه درمان در ماه داشتند در برابر حدود ۱/۹۲ جلسه در گروه دیگر. این همراهی نیازمند تفسیر دقیق است: مراجعه بیشتر می‌تواند با شدت بیشتر مشکلات مرتبط باشد، اما داده‌های موجود وضعیت افراد پیش از شروع درمان یا مسیر تغییر علائم را نشان نمی‌دهند. بنابراین از این نتیجه نمی‌توان درباره مفید یا مضر بودن درمان داوری کرد.

مدل‌ها در این مرحله بر همان داده‌ای ارزیابی شدند که برای فیت کردن به کار رفته بود. در نتیجه، رتبه‌های بالاتر نشان‌دهنده فیت شدن بهتر در همین نمونه‌اند و هنوز عملکرد روی افراد جدید را تایید نمی‌کنند. جست‌وجوی تعداد زیادی ترکیب نیز باعث می‌شود که این رتبه‌بندی و آزمون‌های پس از آن، اکتشافی تلقی شوند.

تا این بخش از تحلیل، روشن‌ترین روایت حول مجموعه‌ای از ویژگی‌های همراه شکل گرفته است: افراد مضطرب، به‌طور متوسط خواب و فعالیت بدنی کمتر، استرس بیشتر و نمره تغذیه پایین‌تری داشتند. بررسی هم‌زمان چند ویژگی نیز نشان داد که کنار هم قرار دادن این اطلاعات، برای توصیف تفاوت دو گروه مفید است.

ارزش این یافته‌ها در مشخص کردن مسیر بررسی دقیق‌تر است. برای تفسیر نهایی همچنان باید منشا و شیوه نمونه‌گیری داده‌ها، اثر جایگزینی مقادیر گمشده، محدودسازی مقادیر انتهایی و نبود اطلاعات زمانی در نظر گرفته شوند. این تحلیل، الگوهای موجود در نمونه را آشکار می‌کند برای تبدیل آن‌ها به ادعایی با علت، توصیه درمانی یا نتیجه‌ای قابل تعمیم، شواهد بیشتری لازم است.